

Universidad Industrial de Santander

Ingeniería en Ciencia de Datos

Aprendizaje de Máquina

Análisis Exploratorio de Datos

Aplicación de técnicas de machine learning para la detección de fallos en maquinaria industrial

María José Chávez Torres – 2251727
Lesly Gabriela Rodríguez – 2251510

Alejandra Moreno Tarazona

Bucaramanga, Santander
2026

Índice

1. Introducción	2
1.1. Contexto del problema	2
1.2. Objetivo del análisis	2
1.3. Justificación del uso de Machine Learning	2
2. Descripción del dataset	2
2.1. Variables y tipos de datos	2
2.2. Estadísticas descriptivas	3
2.3. Revisión de nulos y calidad de datos	3
2.4. Variable objetivo	3
3. Análisis univariado	3
3.1. Distribución de variables numéricas	3
3.2. Distribución de variables categóricas	5
3.3. Análisis de asimetría (skewness)	6
4. Análisis de valores atípicos	6
4.1. Boxplots por Target	6
4.2. Métodos de detección de outliers	7
4.3. Estrategia de manejo de outliers	8
5. Análisis bivariado y multivariado	8
5.1. Matriz de correlación y relación con la variable objetivo	8
5.2. Distribuciones por clase (Target)	9
6. Análisis de tipos de falla (Failure Type)	10
6.1. Distribución de Failure Type	10
6.2. Failure Type según tipo de máquina	10
7. Creación de la variable Temp_diff	11
8. Conclusiones del EDA	12
8.1. Hallazgos principales	12
8.2. Implicaciones para el modelado	12

1. Introducción

1.1. Contexto del problema

El mantenimiento predictivo es una estrategia que busca anticipar posibles fallas en maquinarias antes de que ocurran, permitiendo reducir tiempos de inactividad no planeados y costos asociados a reparaciones urgentes. A diferencia del mantenimiento correctivo, que actúa después de la falla, o del preventivo, que se basa en calendarios fijos, el mantenimiento predictivo utiliza datos de sensores y variables operativas para identificar patrones que anteceden a la falla, permitiendo intervenir en el momento más adecuado.

Este proyecto se trabaja con un dataset que contiene $N = 10,000$ registros y 10 variables asociadas al funcionamiento de máquinas industriales, incluyendo temperatura del aire, temperatura del proceso, velocidad rotacional, torque, desgaste de la herramienta y el tipo de máquina. Nuestra variable objetivo binaria es **Target**, que indica si la máquina falló o no, y además el dataset contiene una variable categórica llamada **Failure Type** que especifica el tipo de falla.

1.2. Objetivo del análisis

El objetivo de este análisis exploratorio de datos es comprender la estructura, calidad y comportamiento de las variables del dataset, con el fin de identificar patrones relevantes que permitan construir modelos de aprendizaje automático capaces de predecir fallas en la maquinaria. Esto implica detectar valores atípicos, entender la relación entre las variables predictoras y la variable objetivo, y caracterizar el desbalance de clases presente en el dataset.

Un aspecto importante a considerar desde el inicio del análisis es el fuerte desbalance de clases: solo el 3,39% de los registros corresponden a casos de falla, lo cual condiciona tanto las técnicas de visualización como las estrategias de modelado que se emplearán más adelante.

1.3. Justificación del uso de Machine Learning

Este problema requiere Machine Learning porque la ocurrencia de una falla no depende de un único umbral en una variable, sino de combinaciones entre temperatura, torque, velocidad y desgaste de herramienta que un modelo puede aprender automáticamente mejor que reglas fijas definidas a mano. Además, se busca tanto predecir si la máquina va a fallar (tarea *binaria*) como identificar qué tipo de falla es más probable (tarea *multiclase*), tareas que un modelo entrenado puede aplicar en tiempo real sobre nuevas lecturas de sensores para anticipar fallas y reducir tiempos de inactividad no planificados.

2. Descripción del dataset

2.1. Variables y tipos de datos

El dataset contiene 10,000 registros y 10 columnas: **UDI** (entero, identificador), **Product ID** (*string*), **Type** (categórica, $\{L, M, H\}$), **Air temperature [K]** (float), **Process temperature [K]** (float), **Rotational speed [rpm]** (entero), **Torque [Nm]** (float), **Tool wear [min]** (entero), **Target** (binaria, $\{0, 1\}$) y **Failure Type** (*string*). No se identificaron columnas con tipos de datos inconsistentes respecto a lo esperado.

2.2. Estadísticas descriptivas

Cuadro 1: Estadísticas descriptivas de las variables numéricas

Variable	Media	Desv. Estándar	Mín	Q1	Mediana	Q3	Máx
Air temperature [K]	300,00	2,00	295,3	298,3	300,1	301,5	304,5
Process temperature [K]	310,01	1,48	305,7	308,8	310,1	311,1	313,8
Rotational speed [rpm]	1538,78	179,28	1168	1423	1503	1612	2886
Torque [Nm]	39,99	9,97	3,8	33,2	40,1	46,8	76,6
Tool wear [min]	107,95	63,65	0	53	108	162	253
Target	0,034	0,181	0	0	0	0	1

La velocidad presenta un máximo de 2886 rpm, un valor muy alejado de $Q_3 = 1612$ rpm, lo cual muestra una asimetría y posibles valores atípicos. A diferencia del torque, que muestra una distribución simétrica alrededor de su media ($\mu \approx 40$ Nm). Además, la media de **Target**, $\mu = 0,034$, confirma que solo el 3,39 % de los registros corresponde a fallos.

2.3. Revisión de nulos y calidad de datos

Se revisó la presencia de valores nulos en cada una de las 10 columnas y no se encontró ningún valor faltante; además, se comprobó la ausencia de registros duplicados. Esto indica que el dataset está completo y no requiere pasos de limpieza antes de continuar con el análisis exploratorio.

2.4. Variable objetivo

La variable a predecir es **Target**, de tipo binaria: 1 indica que la máquina presentó una falla y 0 que operó con normalidad. De los 10,000 registros, solo 339 corresponden a fallas (3,39 %), lo que evidencia un fuerte desbalance de clases que deberá manejarse con métricas como *F1-score*, *recall* o *AUC* en la etapa de modelado, en lugar de *accuracy*.

El dataset incluye la variable **Failure Type**, que detalla el tipo de falla presentada (disipación de calor, potencia, sobreesfuerzo, desgaste de herramienta o fallas aleatorias) para los casos donde **Target** = 1, y que será relevante si se aborda la tarea de clasificación multiclase como complemento a la predicción binaria.

3. Análisis univariado

3.1. Distribución de variables numéricas

Se analizó la distribución de las cinco variables numéricas del dataset (**Air temperature**, **Process temperature**, **Rotational speed**, **Torque** y **Tool wear**) mediante histogramas, con el fin de identificar su forma, simetría y posible presencia de valores atípicos antes de aplicar cualquier transformación o modelo.




Figura 1: Histogramas de las variables numéricas

■ Air temperature [K] y Process temperature [K]

Tipo de variable: cuantitativa continua.

Análisis: presentan distribuciones no normales, sin presencia de valores atípicos. Se utiliza la mediana como medida de tendencia central y el rango intercuartílico (IQR) como medida de dispersión:

$$\begin{aligned} \text{Air temperature [K]} : \quad \tilde{x} &= 300,10 \text{ K}, \quad \text{IQR} = [Q_1, Q_3] = [298,30, 301,50] \text{ K}, \quad \text{IQR} = 3,20 \text{ K} \\ \text{Process temperature [K]} : \quad \tilde{x} &= 310,10 \text{ K}, \quad \text{IQR} = [Q_1, Q_3] = [308,80, 311,10] \text{ K}, \quad \text{IQR} = 2,30 \text{ K} \end{aligned}$$

■ Rotational speed [rpm]

Tipo de variable: cuantitativa continua.

Análisis: presenta una distribución asimétrica positiva (sesgada a la derecha), con presencia de valores atípicos en la cola superior. Debido al sesgo, se emplea la mediana y el IQR:

$$\tilde{x} = 1503,00 \text{ rpm}, \quad \text{IQR} = [1423,00, 1612,00] \text{ rpm}, \quad \text{IQR} = 189,00 \text{ rpm}$$

■ Torque [Nm]

Tipo de variable: cuantitativa continua.

Análisis: presenta una distribución simétrica (aproximadamente normal), con presencia de valores atípicos en las colas. Al mantener simetría, la medida de tendencia central óptima es la media y la de dispersión es la desviación estándar:

$$\mu = 39,98 \text{ Nm}, \quad \sigma = 9,96 \text{ Nm}, \quad \text{Torque} = \mu \pm \sigma = 39,98 \pm 9,96 \text{ Nm}$$

■ Tool wear [min]

Tipo de variable: cuantitativa continua.

Análisis: muestra una distribución asimétrica a lo largo del intervalo operativo (0 a 200 min aprox.), con caídas en la frecuencia hacia los valores máximos. Se utiliza la mediana y el IQR:

$$\tilde{x} = 108,00 \text{ min}, \quad \text{IQR} = [53,00, 162,00] \text{ min}, \quad \text{IQR} = 109,00 \text{ min}$$

3.2. Distribución de variables categóricas

Variable Target (variable objetivo)

Tipo de variable: categórica binaria (0 = sin fallo, 1 = con fallo).

Sin fallo (0) : 9,661 registros (96,61 %) — moda
Con fallo (1) : 339 registros (3,39 %)

Conclusión: muestra un gran desbalance de clases. Esto condiciona la etapa de modelado, haciendo indispensable el uso de técnicas de remuestreo (como SMOTE) y métricas de evaluación enfocadas en la clase minoritaria (*Recall*, *F1-Score*, *PR-AUC*).




Figura 2: Distribución de la variable Target

Variable Failure Type (tipo de falla)

Tipo de variable: categórica nominal multiclase.

Distribución: dominada casi en su totalidad por la categoría *No Failure* (96,61 %). Dentro del subconjunto de fallas reales (3,39 %), las causas más frecuentes son *Heat Dissipation Failure* y *Power Failure*, seguidas por *Overstrain Failure*, *Tool Wear Failure* y *Random Failures*.

Conclusión: confirma que las fallas operativas no ocurren de forma aleatoria uniforme, sino que responden a causas físicas diferentes, siendo los problemas térmicos y de potencia los más prevalentes.

Variable Type (calidad/variante de máquina)

Tipo de variable: categórica ordinal.

L (Low) : 6,000 registros (60,00 %) — moda
 M (Medium) : 2,997 registros (29,97 %)
 H (High) : 1,003 registros (10,03 %)

Conclusión: la mayoría de los equipos en el dataset son de variante de baja calidad o capacidad (L), seguidos por calidad media (M) y alta calidad (H). Esta variable será clave para evaluar si la calidad de la máquina influye directamente en la tasa y tipo de fallo.

3.3. Análisis de asimetría (skewness)

Cuadro 2: Coeficiente de asimetría por variable numérica

Variable	Skewness	Interpretación
Air temperature [K]	0,114	Prácticamente simétrica
Process temperature [K]	0,015	Prácticamente simétrica
Rotational speed [rpm]	1,993	Asimetría positiva marcada
Torque [Nm]	-0,010	Simétrica
Tool wear [min]	0,027	Prácticamente simétrica

Los resultados confirman lo observado en la Sección 3.1: **Rotational speed** es la única variable con asimetría considerable ($\text{skewness} \approx 2$), mientras que el resto presenta valores cercanos a cero. Sin embargo, solo **Torque** cumple también con una forma verdaderamente simétrica, por lo que es la única variable donde se reportó media y desviación estándar; las demás se mantienen con mediana e IQR por las razones de forma explicadas.

4. Análisis de valores atípicos

4.1. Boxplots por Target

Se compararon los *boxplots* de cada variable numérica separando las máquinas que fallaron ($\text{Target} = 1$) de las que no ($\text{Target} = 0$), con el fin de identificar diferencias en la dispersión y en la presencia de valores atípicos entre ambos grupos.




Figura 3: Boxplots de variables numéricas por clase de Target

Las máquinas que fallaron presentan medianas más altas en **Torque** (53,7 Nm vs. 39,9 Nm) y en **Tool wear** (165 min vs. 107 min), así como una mediana ligeramente mayor en **Air temperature** (301,6 K vs. 300,0 K). En contraste, presentan una mediana menor en **Rotational speed** (1365 rpm vs. 1507 rpm). Estas diferencias sugieren que los fallos tienden a ocurrir bajo condiciones operativas más exigentes: mayor esfuerzo (torque), mayor desgaste acumulado y menor velocidad de rotación, lo cual es importante para la etapa de modelado.

4.2. Métodos de detección de outliers

Para identificar valores atípicos se utilizó el método del rango intercuartílico (IQR), por ser un método robusto que no asume una distribución normal de los datos. Se consideraron atípicos los valores fuera del rango:

$$[Q_1 - 1,5 \cdot \text{IQR}, Q_3 + 1,5 \cdot \text{IQR}]$$

Cuadro 3: Valores atípicos detectados por variable (método IQR)

Variable	Outliers detectados	Porcentaje
Air temperature [K]	0	0 %
Process temperature [K]	0	0 %
Rotational speed [rpm]	418	4,18 %
Torque [Nm]	69	0,69 %
Tool wear [min]	0	0 %

Rotational speed es la variable con más valores atípicos (418 registros, equivalentes al 4,18 % del total), lo cual tiene sentido porque ya se había identificado como la variable más asimétrica en el análisis de *skewness*. **Torque** también presenta algunos valores atípicos (69 registros, 0,69 %), ya que su distribución es simétrica y solo unos pocos casos se alejan bastante del resto. Las demás variables (**Air temperature**, **Process temperature** y **Tool wear**) no presentaron valores atípicos según este método.

4.3. Estrategia de manejo de outliers

Dado que las fallas son eventos poco frecuentes (3,39 % del dataset), no se eliminarán los outliers identificados con el método IQR, ya que varios de ellos podrían corresponder específicamente a los casos donde la máquina falló (por ejemplo, valores extremos de torque o desgaste de herramienta), y quitarlos implicaría perder información valiosa para el modelo. Para esto se prefiere:

- Mantener los datos originales para modelos basados en árboles (Random Forest, XG-Boost), que son robustos a outliers por naturaleza.
- Si se llegan a usar modelos sensibles a la escala (regresión logística, SVM, KNN), aplicar **RobustScaler** en lugar de estandarización tradicional, ya que este escalador usa mediana e IQR y es menos sensible a valores atípicos que la media y la desviación estándar.

5. Análisis bivariado y multivariado

5.1. Matriz de correlación y relación con la variable objetivo

Se utilizó la matriz de correlación para evaluar de forma cuantitativa y estructurada la magnitud y dirección de las relaciones entre las variables numéricas del dataset. Esto permite identificar qué variables aportan información importante, entender las dependencias físicas del sistema y detectar qué características influyen de forma directa en el comportamiento del proceso antes de construir un modelo.




Figura 4: Matriz de correlación de las variables numéricas

Se puede evidenciar que las relaciones son en general débiles, pero hay una correlación fuerte entre **Air temperature** y **Process temperature**, así como también entre **Torque [Nm]** y

Rotational speed [rpm] (ambas relaciones tienen un coeficiente $r = 0,88$), lo cual confirma que el dataset captura adecuadamente los principios físicos de operación del equipo.

Para complementar este análisis desde una perspectiva más práctica, se comparó también el promedio de cada variable entre máquinas que fallaron y las que no.

	UDI	Air temperature [K]	Process temperature [K]	Rotational speed [rpm]	Torque [Nm]	Tool wear [min]
Target						
0	5012.878791	299.973999	309.995570	1540.260014	39.629655	106.693717
1	4647.722714	300.886431	310.290265	1496.486726	50.168142	143.781711

Figura 5: Promedio De las variables Cuando la maquina fallo y no fallo

5.2. Distribuciones por clase (Target)

Dado el desbalance de clases que se presenta, se utilizaron histogramas normalizados por densidad para comparar de forma justa la forma de las distribuciones entre máquinas que fallaron (Target = 1) y las que no (Target = 0).




Figura 6: Distribuciones normalizadas por densidad, según clase de Target

Al observar las gráficas se nota que las máquinas que fallaron tienden a tener valores más altos de torque y de desgaste de herramienta que las que no fallaron, mientras que en las demás variables la diferencia entre los dos grupos es menos clara. Esto indica que estas dos variables podrían ser las más útiles para que el modelo distinga entre una máquina que va a fallar y una que no.

6. Análisis de tipos de falla (Failure Type)

6.1. Distribución de Failure Type

Entre los 339 registros donde la máquina falló ($\text{Target} = 1$), se observó que *Heat Dissipation Failure* es el tipo de falla más frecuente con 112 casos, seguido de *Power Failure* con 95 casos, *Overstrain Failure* con 78 casos y *Tool Wear Failure* con 45 casos.




Figura 7: Distribución de la variable Failure Type

Se identificó una inconsistencia menor en los datos: 9 registros con $\text{Target} = 1$ (marcados como falla) aparecen etiquetados como “*No Failure*” en la variable **Failure Type**. Como representan una proporción mínima (9 de 339 casos, 2,65 %), no se considera un problema grave de calidad de datos, pero se tendrá en cuenta en la etapa de modelado, donde estos registros podrían tratarse como ruido o revisarse manualmente antes de entrenar el modelo de clasificación multiclase.

6.2. Failure Type según tipo de máquina

Se busca analizar la distribución y concentración de los tipos de fallas técnicas en relación con la variante de calidad/potencia de la máquina para identificar algún tipo de influencia o vulnerabilidad por categoría de equipo.




Figura 8: Distribución de Failure Type según el tipo de máquina

De acuerdo con la gráfica, se observa una alta concentración de fallos en las máquinas de categoría *L* (235 en total), destacando especialmente en *Heat Dissipation Failure* (74) y *Overstrain Failure* (73). Esto sugiere que las variantes de menor calidad sufren mayor fatiga mecánica y térmica bajo cargas de trabajo estándar.

Por otro lado, hay cierta vulnerabilidad en fallos de potencia, con mayoría de casos en las categorías *L* (59) y *M* (31), lo que indica que las demandas extremas de torque y velocidad impactan de forma representativa a ambos tipos de máquina.

Por el lado de la maquinaria de mayor calidad/capacidad (*H*), contiene la menor cantidad de fallos en todas las categorías (tan solo 8 en *HDF*), lo que confirma su mayor tolerancia a esfuerzos extremos y mejor disipación de la temperatura.

7. Creación de la variable Temp_diff

Se creó una nueva variable, **Temp_diff**, calculada como la diferencia entre la temperatura del proceso y la temperatura del aire:

$$\text{Temp_diff} = \text{Process temperature} - \text{Air temperature}$$

Esta variable busca capturar el efecto del calentamiento del proceso respecto a la temperatura ambiente, algo que ninguna de las dos variables originales refleja por separado, y que surge directamente de la fuerte correlación entre ambas identificada en la Sección 5.1.




Figura 9: Distribución de `Temp_diff` según la clase de `Target`

Las máquinas que fallaron presentan en promedio un `Temp_diff` ligeramente menor (9,40 K) que las que no fallaron (10,02 K), con una correlación $r = -0,112$ respecto a `Target`. Aunque esta relación es débil, es más fuerte que la de `Process temperature` por sí sola ($r = 0,036$), lo que sugiere que `Temp_diff` aporta información adicional sobre la disipación térmica del proceso y podría ser una variable útil a incluir en la etapa de modelado.

8. Conclusiones del EDA

8.1. Hallazgos principales

El dataset no presenta valores nulos ni duplicados, por lo que no se requieren métodos de limpieza de datos. En las variables numéricas, `Air temperature` y `Process temperature` muestran comportamiento multimodal, `Rotational speed` presenta asimetría con valores atípicos, `Torque` es simétrica con algunos outliers en las colas, y `Tool wear` tiene una distribución asimétrica dentro de su rango operativo.

Existe un fuerte desbalance de clases (3,39 % de fallos). `Torque` y `Tool wear` son las variables con mayor relación individual con `Target`, y la variable categórica `Type` influye tanto en la frecuencia general de fallos como en el tipo específico de falla presentada. El tipo de máquina también influye en el tipo de falla presentada, no solo en su ocurrencia. La variable derivada `Temp_diff` aporta información adicional sobre la disipación térmica, con una correlación más fuerte respecto a `Target` ($r = -0,112$) que `Process temperature` por sí sola ($r = 0,036$).

8.2. Implicaciones para el modelado

Para la etapa de modelado se plantea:

- Manejar el desbalance de clases con SMOTE o *undersampling*, evaluando con *F1-score* y *recall* en lugar de *accuracy*.
- Codificar la variable categórica `Type` con *One-Hot Encoding*.
- Incluir `Temp_diff` como variable predictora adicional, dado que mostró mayor relación con `Target` que las temperaturas individuales.
- Probar modelos robustos a outliers, como *Random Forest* o *XGBoost*, como primera aproximación.